

Trabalho Prático 3 - Trilha B

Giovana Lins Cavalcanti¹, Ronald Vieira Cardoso da Silva¹

¹Instituto de Computação – Universidade Federal do Amazonas
Av. Rodrigo Otávio, nº 6200, Coroado I – CEP 69080-900 – Manaus – AM

{giovana.cavalcanti,ronald.silva}@icompu.ufam.edu.br

1. Introdução

Este trabalho tem o objetivo de construir um pequeno marketplace de agentes acadêmicos interoperáveis via o protocolo MCP. Na trilha B, o objetivo específico é criar um agente acadêmico de conteúdo capaz de coletar, avaliar, organizar e expor evidências acadêmicas qualificadas para uma disciplina de graduação da UFAM vinculada a uma prova ENADE publicada com gabarito oficial.

Para isso, escolheu-se a disciplina de Física II E do curso de Engenharia Elétrica, vinculada à área epônima do curso, devido a disponibilidade pública da ementa e prova ENADE com gabarito e padrão de respostas discursivas. Como a ementa está ativa desde 2004 [Curso de Graduação em Eng. Elétrica - Eletrônica 2024], é permitido que sejam utilizadas múltiplas versões da prova do ENADE para Engenharia Elétrica recentes, como a de 2023, 2019 e 2017 [Inep 2025]. O conteúdo associado, incluído na bibliografia da ementa ou não, está amplamente disponível na língua portuguesa múltiplos sites pela web.

2. Metodologia

O agente é dividido em dois componentes: o construtor de corpus, com o objetivo de transformar o texto da ementa em um conjunto de fontes, e o servidor MCP, que provém o conteúdo da disciplina por meio das *tools* do contrato.

2.1. Construtor de corpus

Primeiramente, o texto da entrada passa por um *parsing* que extrai o nome da disciplina, a área do ENADE vinculada, os tópicos, os pré-requisitos e a bibliografia. Como os tópicos e subtópicos não são apresentados de forma separada no texto, é utilizada uma LLM auxiliar para realizar essa classificação. Nesse caso, foi utilizado o modelo Gemma 4 31B, pois demonstrou conhecimento bom de português e respostas em tempo razoável.

Em seguida, é criado um plano de extração de conteúdo da web por meio da ementa pós-*parsing*, definindo fontes e consultas para cada tópico. Após avaliar as diretrizes de uso das fontes admitidas, o tipo de conteúdo que oferecem e as ferramentas disponíveis para extraí-lo, definiu-se que as fontes utilizadas seriam a Wikipedia, consultas na web aberta e consultas na coleção de domínio público do Internet Archive.

A próxima etapa do *pipeline* do construtor é o coletor, o qual utiliza o plano para executar buscas e *fetch* de páginas. Por meio da biblioteca de consultas web DDGS¹ e

¹<https://github.com/deedy5/ddgs>

das APIs oficiais da Wikipedia² e do Internet Archive³, os resultados das consultas nas fontes são armazenados. Ao deparar-se com tags HTML de imagens ou de MathJax, é feita a conversão em markdown e texto puro, respectivamente, permitindo a leitura limpa pelo agente da trilha A. Nota-se que, na consultas web, apenas os 5 primeiros resultados são considerados, e nas consultas de domínio público, apenas os 3 primeiros resultados são considerados. Isso se dá por conta de observações ao realizar algumas consultas manualmente.

O coletor retorna uma lista de documentos que, então, passam por um processo de avaliação. A confiabilidade de um documento foi definida de acordo com seus metadados e conteúdo, incluindo:

- O domínio da fonte, com peso 2, avaliando se a fonte veio de um website cujas informações sobre física tendem a ser verdadeiras. Isso inclui, além da Wikipédia em português e Internet Archive, domínios vinculados às 5 universidades brasileiras com maior qualidade de ensino do curso de Engenharia Elétrica de acordo com o Ranking da Folha de São Paulo de 2024 [Folha de S.Paulo 2024], ano do último ENADE do curso, e sites educativos conhecidos como BrasilEscola, Mundo Educação, Khan Academy e Toda Matéria.
- O idioma da fonte, com peso 1, avaliando se a fonte é escrita em língua portuguesa ou não. Essa verificação é feita de forma heurística: já se sabem quais domínios do critério anterior possuem apenas artigos em português, e o texto do restante pode é verificado por meio da presença de preposições do idioma.
- O tamanho do conteúdo, com peso 2, avaliando o quão substantivo é o conteúdo da fonte, definido ao verificar se o corpo possui mais de 1000 caracteres.
- Ausência de termos de spam, com peso 1, avaliando se a fonte não está poluída com termos como “assine aqui”, “cadastre-se”, etc.

Com o cálculo da média ponderada, os documentos que obtiveram nota igual ou acima de 7,5 são de-duplicados, ou seja, é visto se possuem hash igual e, se sim, são removidos.

Por fim, os documentos são indexados em uma *vector store* com metadados de proveniência. O indexador fragmenta cada documento aprovado em chunks de 200 palavras, com $k=5$ de recuperação. Para cada chunk, são realizados dois procedimentos:

1. É calculado um embedding utilizando a framework Sentence Transformers⁴ com o modelo paraphrase-multilingual-MiniLM-L12-v2, o qual não é persistido.
2. É calculado o hash dos índices e dos metadados, o qual é persistido.

2.2. Servidor MCP

O servidor MCP de conteúdo foi implementado usando a biblioteca FastMCP, expondo uma interface somente de leitura (read-only) sobre o corpus congelado, conforme especificado pelo contrato. Foram disponibilizadas três ferramentas obrigatórias: `list_topics`, para expor os metadados agregados da ementa; `corpus_query`, para busca de evidências relevantes; e `get_chunk`, para recuperação pontual de fragmentos.

²<https://wikipedia-api.readthedocs.io/en/latest/README.html>

³<https://archive.org/developers/internetarchive/python-lib.html>

⁴<https://sbert.net>

Como a regra do projeto proíbe o versionamento de índices de *vector stores*, o arquivo de *embeddings* gerado pelo construtor não é persistido no repositório. Para solucionar isso, o servidor adota uma estratégia de resiliência: durante a sua inicialização, ele recomputa dinamicamente os *embeddings* dos *chunks* em memória utilizando o modelo local citado anteriormente. Isso garante que a busca semântica por similaridade de cosseno funcione perfeitamente em qualquer ambiente clonado, possuindo também um *fallback* seguro para busca por palavras-chave caso ocorra falha na inferência. A comunicação do servidor respeita rigorosamente o envelope JSON estabelecido. Exceções internas (como índices inválidos ou consultas malformadas) são capturadas e convertidas em erros estruturados com códigos canônicos (e.g., `MALFORMED_QUERY`), garantindo estabilidade para o agente cliente.

3. Resultados

A aderência dessa arquitetura foi atestada com sucesso pela ferramenta oficial `check_contract`, alcançando 12/12 requisitos satisfeitos. Após isso, foi feita validação contra o tutor mock, que retornou positivo para a integridade da sessão.

4. Discussão

Percebeu-se que qualificar a credibilidade das fontes requer diminuir sua diversidade: há muitos sites que expõem conteúdo de física II na web, mas poucos são conhecidos. Além disso, como a disciplina envolve múltiplas fórmulas, podem haver discrepâncias ao converter conteúdos em PDF para texto legível por LLMs. Como sites que oferecem conteúdo de domínio público e sites institucionais tendem a armazenar esses tipo de arquivo, isso é uma limitação possivelmente notável.

Tentou-se utilizar apenas fontes facilmente acessíveis e que não tivessem direitos autorais, porém, devido a natureza das pesquisas na web aberta, é possível que alguns conteúdos coletados possuam licenças não consideradas. O maior risco encontra-se no Internet Archive, pois há a possibilidade que um usuário tenha subido um livro com direitos autorais reservados na coleção pública.

Um ponto positivo do sistema é que, devido ao uso de embeddings, ementas de outras disciplinas podem ser utilizadas e o agente ainda será capaz de prover conteúdos. Devido ao tratamento do coletor, o agente está especialmente preparado para lidar com disciplinas de exatas, dado que as fontes sejam de sites da web na estrutura esperada de HTML, como a maioria dos sites.

Referências

- Curso de Graduação em Eng. Elétrica - Eletrônica (2024). Matriz curricular e ementas. Disponível em <https://www.eletronica.sites.ufam.edu.br/matriz-curricular-e-ementas.html>. Acessado em 4 de julho de 2026.
- Folha de S.Paulo (2024). Ranking de cursos de graduação. Disponível em <https://ruf.folha.uol.com.br/2024/ranking-de-cursos/engenharia-eletrica/>. Acessado em 8 de julho de 2026.
- Inep (2025). Provas e gabaritos. Disponível em <https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/enade/provas-e-gabaritos>. Acessado em 4 de julho de 2026.